


HASIL EVALUASI MODEL

1. Hasil

Berikut merupakan hasil pemrograman dengan Google Colab yang menampilkan *confusion matrix* dan *classification report* dari topik sentimen komentar Instagram, dilampirkan dengan gambar dibawah.



Gambar 1. *Confusion Matrix*

CLASSIFICATION REPORT				
Kelas Target	Precision (Ketepatan)	Recall (Sensitivitas)	f1-score (Keseimbangan)	Support (Jumlah Sampel)
Negative	0.78	0.88	0.82	40
Positive	0.86	0.75	0.80	40

2. Pengujian Data dan Nilai Akurasi

Pengujian performa model dilakukan melalui metode eksperimen dengan membagi subset dataset menjadi data pelatihan (*training data*) sebesar 80% (320 sampel) dan data pengujian (*testing data*) sebesar 20% (80 sampel). Pembagian data dilakukan secara acak namun tetap

mempertahankan distribusi kelas yang seimbang (*stratified splitting*) guna menjamin objektivitas evaluasi sistem.

Berdasarkan hasil eksekusi program di Google Colab, model klasifikasi berbasis algoritma *Multinomial Naive Bayes* yang diintegrasikan dengan pembobotan fitur *Term Frequency-Inverse Document Frequency* (TF-IDF) mencatatkan performa yang cukup tinggi.

Dari total 80 baris data teks komentar Instagram yang diujikan secara acak pada sistem, model kecerdasan buatan ini mampu memprediksi dengan benar sebanyak 65 data teks, dan hanya menyisakan galat (salah tebak) sebanyak 15 data teks. Hasil ini membuktikan bahwa arsitektur pemrograman *Natural Language Processing* (NLP) yang dirancang telah matang dan reliabel untuk mengenali pola teks cyberbullying.

3. Analisis Matriks Evaluasi (Confusion Matrix)

Untuk membedah secara detail kualitas prediksi model serta mengidentifikasi sebaran kesalahan tebak sistem antara kelas positif dan kelas negatif, evaluasi dilakukan menggunakan visualisasi grafik *Confusion Matrix*. Distribusi biner dari hasil pengujian 80 data tersebut dijabarkan sebagai berikut:

1. *True Negative* (TN) = 35: Sistem berhasil mendeteksi secara tepat 35 komentar yang secara aktual memang bersentimen *Negative* (mengandung unsur perundungan/ujaran kebencian).
2. *True Positive* (TP) = 30: Sistem berhasil mendeteksi secara tepat 30 komentar yang secara aktual memang bersentimen *Positive* (berisi kalimat pujian, dukungan, atau teks netral yang aman).
3. *False Positive* (FP) = 5: Terjadi galat Tipe I (*False Alarm*), di mana terdapat 5 komentar aktual bersentimen *Negative* namun sistem keliru mengklasifikasikannya ke dalam prediksi sentimen *Positive*.
4. *False Negative* (FN) = 10: Terjadi galat Tipe II, di mana hanya ada 10 komentar aktual bersentimen *Positive* namun sistem salah mengelompokkannya ke dalam prediksi sentimen *Negative*.

4. Pembahasan Temuan Eksperimen dan Demo Sistem

Berdasarkan analisis korpus teks, model *Multinomial Naive Bayes* menjadi sangat peka karena kata-kata makian atau kata radikal tertentu memiliki frekuensi kemunculan yang pekat pada dokumen berlabel negatif, sehingga kata-kata tersebut mendapatkan bobot nilai statistik yang sangat tinggi. Ketika sebuah teks komentar baru dimasukkan pada sesi demo interaktif, keberadaan satu kata kunci radikal tersebut secara probabilistik akan langsung menarik kesimpulan prediksi

ke arah kelas *Negative*.

Meskipun demikian, sistem masih menyisakan batas error sebesar 18.75% (15 data salah tebak). Setelah dilakukan penelusuran pada baris data yang mengalami galat, kesalahan prediksi disebabkan oleh beberapa faktor linguistik media sosial, antara lain:

- Penggunaan Kata Negasi Gangan atau Sarkasme: Kalimat sindiran halus yang menggunakan kata-kata positif namun bermakna ejekan sering kali mengecoh model, karena Naive Bayes membaca kata secara independen (*Bag of Words*) dan belum mampu menangkap konteks emosi tersirat secara utuh.
- Variasi Penulisan Kata Non-Baku: Adanya singkatan atau modifikasi karakter huruf oleh netizen (misalnya "*kya*", "*bgt*") membuat kata tersebut tidak berhasil diubah ke kata dasar asli pada proses *stemming* Sastrawi, sehingga AI gagal mengenali bobot penting kata tersebut.

Secara keseluruhan, visualisasi matriks yang didominasi oleh area diagonal utama (TN dan TP) membuktikan bahwa pemanfaatan data seimbang (*balanced dataset*) sangat sukses memitigasi risiko *overfitting*, sehingga program prototype ini siap digunakan untuk simulasi pengujian interaktif secara nyata.